Aprendendo R

Magno TF Severino

2024-01-12

Contents

Introdução

Este livro compila tutoriais da linguagem `R` que usei em diversas aulas que dei ao longo dos últimos anos e foi escrito baseado em Cotton (2013) e Wickham et al. (2023).

Visite minha página no github.

Chapter 1

Básicos da linguagem R

> O conteúdo apresentado aqui foi usado na primeira aula prática do curso de "Aprendizagem Estatística com Aplicações em R".

Para instalação,

- faça o download do R em http://www.r-project.org;
- sugestão: utilizar a IDE R Studio.

É muito importante saber como obter ajuda no R. Sempre que estiver em dúvidas quanto as características de alguma função, consule a aba *help* do RStudio.

```
?mean #abre a página de ajuda da função 'mean'
??plot #procura por tópicos contendo a palavra 'plot'
```

1.1 Usando o R como uma calculadora

O operador + realiza a adição entre dois elementos.

```
1 + 2
```

```
## [1] 3
```

Um vetor é um conjunto ordenado de valores. O operador : cria uma sequência a partir de um número até outro. A função c concatena valores, criando um vetor.

```r
1:5
```

```
## [1] 1 2 3 4 5
```

```r
c(1, 2, 3, 4, 5)
```

```
## [1] 1 2 3 4 5
```

Além de adicionar dois números, o operador + pode ser usado para adicionar dois vetores.

```r
1:5 + 6:10
```

```
## [1]  7  9 11 13 15
```

```r
c(1, 2, 3, 4, 5) + c(6, 7, 8, 9, 10)
```

```
## [1]  7  9 11 13 15
```

```r
1:5 + c(6, 7, 8, 9, 10)
```

```
## [1]  7  9 11 13 15
```

Os próximos exemplos mostram subtração, multiplicação, exponenciação e divisão.

```r
c(2, 3, 5, 7, 11, 13) - 2       #subtração
```

```
## [1]  0  1  3  5  9 11
```

```r
-2:2 * -2:2                     #multiplicação
```

```
## [1] 4 1 0 1 4
```

```r
(1:10) ^ 2                        #exponenciação
```

```
##  [1]   1   4   9  16  25  36  49  64  81 100
```

```
1:10 / 3                          #divisão
```

```
##  [1] 0.3333333 0.6666667 1.0000000 1.3333333 1.6666667 2.0000000 2.3333333
##  [8] 2.6666667 3.0000000 3.3333333
```

1.2 Atribuindo variáveis

Fazer cálculos com o R é bem simples e útil. A maior parte das vezes queremos armazenar os resultados para uso posterior. Assim, podemos atribuir valor à uma variável, através do operador <-.

```
a <- 1

b <- 5 * 3

x <- 1:5

y <- 6:10
```

Agora, podemos reutilizar esses valores para fazer outros cálculos.

```
a + 2 * b
```

```
## [1] 31
```

```
x + 2 * y - 3
```

```
## [1] 10 13 16 19 22
```

Observe que não temos que dizer ao R qual o tipo da variável, se era um número (as variáveis a e a) ou vetor (x e y).

1.3 Números especias

Para facilitar operações aritméticas, R suporta quatro valores especiais de números: Inf, -Inf, NaN e NA. Os dois primeiros representam infinito positivo e negativo. NaN é um acrônimo inglês para “not a number”, ou seja, não é um número. Ele aparece quando um cálculo não faz sentido, ou não está definido. NA significa “not available”, ou seja, não disponível, e representa um valor faltante.

```
c(Inf + 1, Inf - 1, Inf - Inf, NA + 1)
```

```
## [1] Inf Inf NaN  NA
```

```
c(0 / 0, Inf / Inf, 1 / Inf)
```

```
## [1] NaN NaN   0
```

1.4 Vetores, Matrizes e Dataframes

Previamente, vimos alguns tipos de vetores para valores lógicos, caracteres e números. Nessa seção, utilizaremos técnicas de manipulação de vetores e introduziremos o caso multidimensional: matrizes e dataframes.

Abaixo relembramos as operações que já foram feitas com vetores

```
10:5                    #sequência de números de 10 até 5
```

```
## [1] 10  9  8  7  6  5
```

```
c(1, 2:5, c(6, 7), 8)   #valores concatenados em um único vetor
```

```
## [1] 1 2 3 4 5 6 7 8
```

1.4.1 Vetores

Existem funções para criar vetores de um tipo e com tamanho específicos. Todos os elementos deste vetor terá valor zero, FALSE, um caracter vazio, ou o equivalente à *nada/vazio* para aquele tipo. Veja abaixo duas maneiras de definir um vetor.

```
vector("numeric", 5) #cria um vetor numérico de 5 elementos
```

```
## [1] 0 0 0 0 0
```

```
numeric(5) #equivalente ao comando acima
```

```
## [1] 0 0 0 0 0
```

```r
vector("logical", 5) #cria um vetor lógico de 5 elementos
```

```
## [1] FALSE FALSE FALSE FALSE FALSE
```

```r
logical(5) #equivalente ao comando acima
```

```
## [1] FALSE FALSE FALSE FALSE FALSE
```

```r
vector("character", 5) #cria um vetor de caracteres de 5 elementos
```

```
## [1] "" "" "" "" ""
```

```r
character(5) #equivalente ao comando acima
```

```
## [1] "" "" "" "" ""
```

1.4.1.1 Sequências

Podemos criar sequências mais gerais que aquelas criadas com o operador :. A função seq te permite criar sequências em diferentes maneiras Veja abaixo.

```r
seq(3, 12) #equivalente à 3:12
```

```
##  [1]  3  4  5  6  7  8  9 10 11 12
```

```r
seq(3, 12, 2) #o terceiro argumento indica a distância entre os elementos na lista.
```

```
## [1]  3  5  7  9 11
```

```r
seq(0.1, 0.01, -0.01)
```

```
##  [1] 0.10 0.09 0.08 0.07 0.06 0.05 0.04 0.03 0.02 0.01
```

1.4.1.2 Tamanhos

Todo vetor tem um tamanho, um número não negativo que representa a quantidade de elementos que o vetor contém. A função length retorna o tamanho de um dado vetor.

```
length(1:5)
```

```
## [1] 5
```

```
frase <- c("Observe", "o", "resultado", "dos", "comandos", "abaixo")

length(frase)
```

```
## [1] 6
```

```
nchar(frase)
```

```
## [1] 7 1 9 3 8 6
```

1.4.1.3 Indexando vetores

A indexação é útil quando queremos acessar elementos específicos de um vetor. Considere o vetor

```
x <- (1:5) ^ 2
```

Abaixo, três métodos de indexar os mesmos valores do vetor x.

```
x[c(1, 3, 5)]

x[c(-2, -4)]

x[c(TRUE, FALSE, TRUE, FALSE, TRUE)]
```

```
## [1]  1  9 25
```

Se nomearmos os elementos do vetor, o método abaixo obtém os mesmos valores de x.

```
names(x) <- c("one", "four", "nine", "sixteen", "twenty five")
x[c("one", "nine", "twenty five")]
```

```
##         one        nine twenty five
##           1           9          25
```

Cuidado, acessar um elemento fora do tamanho do vetor não gera um erro no R, apenas NA.

```
x[6]
```

```
## <NA>
##   NA
```

1.4.2 Matrizes

Uma matriz é o equivalente à um vetor, porém em duas dimensões. Abaixo, um exemplo de definição de uma matriz com 4 linhas e 3 colunas (total de 12 elementos).

```
?matrix
```

```
uma_matriz <- matrix(
      1:12,
      nrow = 4, #ncol = 3 gera o mesmo resultado. Verifique!
      dimnames = list(
        c("L1", "L2", "L3", "L4"),
        c("C1", "C2", "C3")
      )
)

class(uma_matriz)
```

```
## [1] "matrix" "array"
```

```
uma_matriz
```

```
##    C1 C2 C3
## L1  1  5  9
## L2  2  6 10
## L3  3  7 11
## L4  4  8 12
```

Por padrão, ao criar uma matrix, o vetor passado como primeiro argumento preenche a matrix por colunas. Para preencher a matrix por linhas, basta especificar o argumento byrow=TRUE

A função dim retorna um vetor de inteiros com as dimensões da variável.

```
dim(uma_matriz)
```

```
## [1] 4 3
```

```r
nrow(uma_matriz) #retorna o número de linhas da matrix
```

```
## [1] 4
```

```r
ncol(uma_matriz) #retorna o número de colunas da matrix
```

```
## [1] 3
```

```r
length(uma_matriz) #retorna o número de elementos da matrix
```

```
## [1] 12
```

1.4.2.1 Nomeando linhas, columas e dimensões

Da mesma forma para vetores, podemos nomear (e obter os nomes de) linhas e colunas de matrizes.

```r
rownames(uma_matriz)
```

```
## [1] "L1" "L2" "L3" "L4"
```

```r
colnames(uma_matriz)
```

```
## [1] "C1" "C2" "C3"
```

```r
dimnames(uma_matriz)
```

```
## [[1]]
## [1] "L1" "L2" "L3" "L4"
##
## [[2]]
## [1] "C1" "C2" "C3"
```

1.4.2.2 Indexação

A indexação de matrizes funciona de maneira similar à de vetores, com a diferença que agora precisam ser especificadas mais de uma dimensão.

```
uma_matriz[1, c("C2", "C3")] #elementos na primeira linha, segunda e terceira colunas
```

```
## C2 C3
##  5  9
```

```
uma_matriz[1, ] #todos elementos da primeira linha
```

```
## C1 C2 C3
##  1  5  9
```

```
uma_matriz[, c("C2", "C3")] #todos elementos da segunda e terceira colunas
```

```
##    C2 C3
## L1  5  9
## L2  6 10
## L3  7 11
## L4  8 12
```

```
uma_matriz[, c(2, 3)] #todos elementos da segunda e terceira colunas
```

```
##    C2 C3
## L1  5  9
## L2  6 10
## L3  7 11
## L4  8 12
```

1.4.2.3 Combinando matrizes

Considere a seguinte matriz.

```
outra_matriz <- matrix(
      seq(2, 24, 2),
      nrow = 4,
      dimnames = list(
        c("L5", "L6", "L7", "L8"),
        c("C5", "C6", "C7")
      ))
```

A combinação de matrizes pode ser feita através das funções cbind e rbind, que combina matrizes por colunas e por linhas, respectivamentes.

```
cbind(uma_matriz, outra_matriz)
```

```
##    C1 C2 C3 C5 C6 C7
## L1  1  5  9  2 10 18
## L2  2  6 10  4 12 20
## L3  3  7 11  6 14 22
## L4  4  8 12  8 16 24
```

```
rbind(uma_matriz, outra_matriz)
```

```
##    C1 C2 C3
## L1  1  5  9
## L2  2  6 10
## L3  3  7 11
## L4  4  8 12
## L5  2 10 18
## L6  4 12 20
## L7  6 14 22
## L8  8 16 24
```

1.4.2.4 Operações com matrizes

As operações básicas (+, -, *, /) funcionam de elemento a elemento em matrizes, da mesmo forma como em vetores:

```
uma_matriz + outra_matriz
```

```
##    C1 C2 C3
## L1  3 15 27
## L2  6 18 30
## L3  9 21 33
## L4 12 24 36
```

```
uma_matriz * outra_matriz
```

```
##    C1  C2  C3
## L1  2  50 162
## L2  8  72 200
## L3 18  98 242
## L4 32 128 288
```

Cuidado: as matrizes e vetores devem ter tamanhos compativeis!

1.4.3 Data frames

```
um_data_frame <- data.frame(
  x = letters[1:5],       #coluna de caracteres
  y = rnorm(5),           #coluna de numeros
  z = runif(5) > 0.5      #coluna de logicos
)
um_data_frame
```

```
##   x          y     z
## 1 a -0.8233980  TRUE
## 2 b  0.1307668  TRUE
## 3 c  0.1691104 FALSE
## 4 d  0.5612312 FALSE
## 5 e -0.1864049 FALSE
```

```
class(um_data_frame)
```

```
## [1] "data.frame"
```

```
rownames(um_data_frame) #nome das linhas do dataframe
```

```
## [1] "1" "2" "3" "4" "5"
```

```
colnames(um_data_frame) #nome das colunas do dataframe
```

```
## [1] "x" "y" "z"
```

```
length(um_data_frame) #retorna o numero de colunas do dataframe (diferente de matriz)
```

```
## [1] 3
```

```
ncol(um_data_frame) #numero de linhas do dataframe
```

```
## [1] 3
```

```
nrow(um_data_frame) #numero de colunas do dataframe
```

```
## [1] 5
```

```r
dim(um_data_frame) #dimensao do dataframe
```

```
## [1] 5 3
```

```r
#### Indexação de dataframes

um_data_frame[2:3, -3] #o segundo e o terceiro elementos das duas primeiras colunas do
```

```
##   x         y
## 2 b 0.1307668
## 3 c 0.1691104
```

```r
class(um_data_frame[2:3, -3]) #observe que o resultado é um dataframe
```

```
## [1] "data.frame"
```

```r
um_data_frame[c(FALSE, TRUE, TRUE, FALSE, FALSE), c("x", "y")] #mesmo resultado que ac
```

```
##   x         y
## 2 b 0.1307668
## 3 c 0.1691104
```

```r
um_data_frame[2:3, 1]
```

```
## [1] "b" "c"
```

```r
class(um_data_frame[2:3, 1]) #como selecionamos um vetor, a classe é a mesma do elemen
```

```
## [1] "character"
```

```r
um_data_frame$x #seleciona a coluna x
```

```
## [1] "a" "b" "c" "d" "e"
```

```r
um_data_frame$x[2:3] #seleciona os elementos 2 e 3 da coluna x
```

```
## [1] "b" "c"
```

```
um_data_frame[[1]][2:3] #equivalente ao comando acima
```

```
## [1] "b" "c"
```

```
um_data_frame[["x"]][2:3] #equivalente ao comando acima
```

```
## [1] "b" "c"
```

1.4.3.1 Manipulação de dataframes

```
novo_data_frame <- data.frame( #mesmas colunas que o dataframe anterior, ordem diferente
  z = rlnorm(5), #números distribuídos seguindo a distribuição lognormal
  y = sample(5), #número 1 a 5 distribuidos em uma ordem aleatória
  x = letters[3:7])

rbind(um_data_frame, novo_data_frame) #qual a dimensão deste elemento?
```

```
##    x          y         z
## 1  a -0.8233980 1.0000000
## 2  b  0.1307668 1.0000000
## 3  c  0.1691104 0.0000000
## 4  d  0.5612312 0.0000000
## 5  e -0.1864049 0.0000000
## 6  c  2.0000000 2.3400866
## 7  d  4.0000000 0.8160785
## 8  e  5.0000000 0.8653514
## 9  f  1.0000000 1.4635845
## 10 g  3.0000000 0.1219754
```

```
cbind(um_data_frame, novo_data_frame) #qual a dimensão deste elemento?
```

```
##   x          y     z         z y x
## 1 a -0.8233980  TRUE 2.3400866 2 c
## 2 b  0.1307668  TRUE 0.8160785 4 d
## 3 c  0.1691104 FALSE 0.8653514 5 e
## 4 d  0.5612312 FALSE 1.4635845 1 f
## 5 e -0.1864049 FALSE 0.1219754 3 g
```

```
?merge #Para mesclar dois dataframes, devemos considerar uma coluna que contenha algum identifica
```

```r
merge(um_data_frame, novo_data_frame, by = "x")  #mescla os dataframes atraves da colu
```

```
##   x        y.x   z.x       z.y y.y
## 1 c  0.1691104 FALSE 2.3400866   2
## 2 d  0.5612312 FALSE 0.8160785   4
## 3 e -0.1864049 FALSE 0.8653514   5
```

```r
merge(um_data_frame, novo_data_frame, by = "x", all = TRUE) #o que o argumento all=TRU
```

```
##   x        y.x   z.x       z.y y.y
## 1 a -0.8233980  TRUE        NA  NA
## 2 b  0.1307668  TRUE        NA  NA
## 3 c  0.1691104 FALSE 2.3400866   2
## 4 d  0.5612312 FALSE 0.8160785   4
## 5 e -0.1864049 FALSE 0.8653514   5
## 6 f         NA    NA 1.4635845   1
## 7 g         NA    NA 0.1219754   3
```

Chapter 2

Controle de fluxo e repetição

> Este capítulo foi escrito baseado em Cotton (2013) e o conteúdo apresentado aqui foi usado como base para o minicurso "R para não-programadores" que ministrei junto com a prof. Marina Bicudo.

Por algum motivo particular, você pode querer executar ou não um determinado trecho do seu código. Também, pode querer que um trecho seja executado repetidas vezes.

2.0.1 `if` e `else`

A maneira mais simples de controlar o fluxo de execução é adicionando um valor lógico e executando o comando `if`.

```
if(TRUE) message("Isso é verdadeiro!")
```

```
## Isso é verdadeiro!
```

```
if(FALSE) message("Isso não é verdadeiro!")

if(is.na(NA)) message("O valor está faltando!")
```

```
## O valor está faltando!
```

```r
if(runif(1) > 0.5) message("Essa mensagem ocorre com 50% de chance.")

x <- 3
if(x > 2) {
  y <- 2 * x
  z <- 3 * y
}
```

Para executar um comando caso a condição do `if` não seja verdadeira, utilize o `else`.

```r
if(FALSE)
{
   message("Não será executado...")
} else #o else deve estar na mesma linha que fecha as chaves
{
   message("mas este será.")
}
```

```
## mas este será.
```

Como R é uma linguagem vetorizada, é possível vetorizar estruturas de controle de fluxo, através da função `ifelse`. Esta função necessita de três argumentos: o primeiro é um vetor de valor lógico, o segundo contém os valores que serão retornados quando a condição lógica é verdadeira (`TRUE`), o terceiro contem os valores que serão retornados quando a condição é falsa (`FALSE`).

```r
set.seed(123)
numeros <- sample(1:100, 10)

maiores_50 <- ifelse(numeros > 50, "Maior que 50", "Menor ou igual a 50")

maiores_50 <- factor(maiores_50)
table(maiores_50)
```

```
## maiores_50
##        Maior que 50 Menor ou igual a 50
##                   4                   6
```

2.0.2 Estruturas de repetição

2.0.2.1 `while`

O `while` primeiramente checa a condição e, caso verdadeira, a executa. No exemplo abaixo, o `while` será executado somente se `acao` for diferente de "Des-

cansar".

```
acoes <- c( "Aprender a programar em R",
        "Fazer um café",
        "Assistir um filme",
        "Descansar")

acao <- sample(acoes, 1)

print(acao)
```

```
## [1] "Fazer um café"
```

```
while(acao != "Descansar") {
  acao <- sample(acoes, 1)
  print(acao)
}
```

```
## [1] "Assistir um filme"
## [1] "Descansar"
```

2.0.2.2 `for`

É usado quando se sabe exatamente quantas vezes o trecho de código deverá ser repetido. O `for` aceita uma variável iterativa bem como um vetor. O loop é repetido, dando ao iterador cada elemento do vetor por vez. O caso mais simples é um vetor contendo inteiros.

```
for(i in 1:5) {
  j <- i ^ 2
  print(paste("j = ", j))
}
```

```
## [1] "j =  1"
## [1] "j =  4"
## [1] "j =  9"
## [1] "j =  16"
## [1] "j =  25"
```

```
for(month in month.name)
{
 print(paste0("The month of ", month))
}
```

```
## [1] "The month of January"
## [1] "The month of February"
## [1] "The month of March"
## [1] "The month of April"
## [1] "The month of May"
## [1] "The month of June"
## [1] "The month of July"
## [1] "The month of August"
## [1] "The month of September"
## [1] "The month of October"
## [1] "The month of November"
## [1] "The month of December"
```

No exemplo abaixo, sorteamos 10 números entre 1 e 100 e, para cada número, se ele for par, calculamos o quadrado, se for impar, somamos 1.

```
set.seed(2)

numeros <- sample(1:100, 10)
resultado <- numeric(length(numeros))
for(i in 1:length(numeros)) {
  if(numeros[i] %% 2 == 0)
    resultado[i] <- numeros[i]^2
  else
    resultado[i] <- numeros[i]+1
}

rbind(numeros, resultado)
```

```
##           [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10]
## numeros     85   79   70    6   32    8   17   93   81    76
## resultado   86   80 4900   36 1024   64   18   94   82  5776
```

Uma alternativa é usar a função `ifelse` para fazer a mesma operação acima.

```
ifelse(numeros %% 2 == 0, numeros^2, numeros+1)
```

```
##  [1]   86   80 4900   36 1024   64   18   94   82 5776
```

2.1 Funções

Os tipos e estruturas de variáveis são importantes para armazenamento de dados, funções nos permitem processar os dados.

2.1.0.0.1 Criando e chamando funções Uma função é criada de maneira parecida com a criação de variáveis, atribuindo um nome à função.

```
hipotenusa <- function(x, y) {
  sqrt(x^2 + y^2)
}
```

Aqui, `hipotenusa` é o nome da função criada, `x` e `y` são os argumentos e o conteúdo entre chaves é chamado de corpo da função.

```
hipotenusa(3, 4) #sem nomear, os parametros sao considerados seguindo a ordem de definicao da fu
```

```
## [1] 5
```

```
hipotenusa(y=24, x=7)
```

```
## [1] 25
```

Pode-se definir valores padrão para argumentos de uma função. Na função abaixo, que calcula a potenciação, caso `exp` não seja definido, a função calculará o quadrado do número dado.

```
potencia <- function(base, exp = 2) {
  base ^ exp
}

potencia(10)
```

```
## [1] 100
```

```
potencia(10, 3)
```

```
## [1] 1000
```

```
potencia(c(1:10, NA))
```

```
##  [1]   1   4   9  16  25  36  49  64  81 100  NA
```

2.2 Lista de exercicios

1. O comando abaixo gera amostras aleatórias seguindo a distribuição binomial para simular o lançamento de 100 moeda.

```
set.seed(1)
lancamentos <- rbinom(100, 1, 0.5)
```

Considere que 0 represente "cara" e 1 represente "coroa." Crie uma variavel para armazenar os lançamentos como um fator contendo os níveis "cara" e "coroa".

2. Para fins de exemplo, neste exercício considere apenas uma amostra de 1000 linhas dos dados armazenados no dataframe `flights` do pacote `nycflights`.

```
library(nycflights13)
```

```
## Warning: package 'nycflights13' was built under R version 4.2.3
```

```
set.seed(1)

flights <- flights[sample(1:nrow(flights), 1000),]
```

a) De acordo com a descrição do mesmo (veja `?flights`), a coluna `distance` está registrada em milhas. Crie uma função que receba como argumento um número em milhas e converta-o para kilometros (para um resultado aproximado, multiplique o valor de comprimento por 1,609). Em seguida, crie um novo dataframe, `flights2` em que sua coluna distance esteja representada em km.

b) Crie uma sequencia de comandos utilizando a estrutura `for` para classificar cada uma das distâncias obtidas no item anterior em "curta distância" (até 500km), "média distância" (entre 500km e 2000km) e "longa distância" (mais que 2000km). Armazene o resultado obtido em uma nova coluna no datafrarme `flights`. Transforme essa coluna em fator.

Chapter 3

Importação e manipulação de bases de dados

> Este capítulo foi escrito baseado em Cotton (2013) e o conteúdo apresentado aqui foi usado como base para o minicurso "R para não-programadores".

O tipo de dados mais comum de ser importado para o `R` são aqueles que são armazenadas em planilhas. Nesta aula, vamos trabalhar com os dados contidos na biblioteca `nycflights13`, porém, vamos conosiderar a versão dos dados salvos em arquivos `.csv`.
Para importar dados do tipo `.csv` (valores separados por vírgula), utilize o comando abaixo.

```
flights <- read.csv("flights.csv")
airports <- read.csv("airports.csv")

class(flights)
```

```
## [1] "data.frame"
```

```
class(airports)
```

```
## [1] "data.frame"
```

Veja a seguinr os comandos para analisar a estrutura dos dados e obter uma descrição do tipo de cada coluna presente na base.

```
str(flights)
```

```
## 'data.frame':    336776 obs. of  20 variables:
##  $ X             : int  1 2 3 4 5 6 7 8 9 10 ...
##  $ year          : int  2013 2013 2013 2013 2013 2013 2013 2013 2013 2013 ...
##  $ month         : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ day           : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ dep_time      : int  517 533 542 544 554 554 555 557 557 558 ...
##  $ sched_dep_time: int  515 529 540 545 600 558 600 600 600 600 ...
##  $ dep_delay     : int  2 4 2 -1 -6 -4 -5 -3 -3 -2 ...
##  $ arr_time      : int  830 850 923 1004 812 740 913 709 838 753 ...
##  $ sched_arr_time: int  819 830 850 1022 837 728 854 723 846 745 ...
##  $ arr_delay     : int  11 20 33 -18 -25 12 19 -14 -8 8 ...
##  $ carrier       : chr  "UA" "UA" "AA" "B6" ...
##  $ flight        : int  1545 1714 1141 725 461 1696 507 5708 79 301 ...
##  $ tailnum       : chr  "N14228" "N24211" "N619AA" "N804JB" ...
##  $ origin        : chr  "EWR" "LGA" "JFK" "JFK" ...
##  $ dest          : chr  "IAH" "IAH" "MIA" "BQN" ...
##  $ air_time      : int  227 227 160 183 116 150 158 53 140 138 ...
##  $ distance      : int  1400 1416 1089 1576 762 719 1065 229 944 733 ...
##  $ hour          : int  5 5 5 5 6 5 6 6 6 6 ...
##  $ minute        : int  15 29 40 45 0 58 0 0 0 0 ...
##  $ time_hour     : chr  "2013-01-01 05:00:00" "2013-01-01 05:00:00" "2013-01-01 05:0
```

```
str(airports)
```

```
## 'data.frame':    1458 obs. of  9 variables:
##  $ X    : int  1 2 3 4 5 6 7 8 9 10 ...
##  $ faa  : chr  "04G" "06A" "06C" "06N" ...
##  $ name : chr  "Lansdowne Airport" "Moton Field Municipal Airport" "Schaumburg Regio
##  $ lat  : num  41.1 32.5 42 41.4 31.1 ...
##  $ lon  : num  -80.6 -85.7 -88.1 -74.4 -81.4 ...
##  $ alt  : int  1044 264 801 523 11 1593 730 492 1000 108 ...
##  $ tz   : int  -5 -6 -6 -5 -5 -5 -5 -5 -5 -8 ...
##  $ dst  : chr  "A" "A" "A" "A" ...
##  $ tzone: chr  "America/New_York" "America/Chicago" "America/Chicago" "America/New_Y
```

Frequentemente, você deverá alterar o tipo de alguma(s) coluna(s), como, por exemplo, para tratar dados do tipo fator, caracteres e datas.

Nos dados armazenados em `flights`, podemos converter as colunas `carrier`, `orign` e `dest` para fator.

```
flights$carrier <- as.factor(flights$carrier)

flights$origin <- as.factor(flights$origin)

flights$dest <- as.factor(flights$dest)
```

Na tabela airport, podemos converter a coluna `tzone` para o tipo fator.

```
airports$tzone <- as.factor(airports$tzone)
```

Note que a coluna `flights$time_hour` representa a hora data e hora do voo. Com a função `head()` podemos visualizar as primeiras observações de uma coluna (e de um data frame também).

```
head(flights$time_hour)
```

```
## [1] "2013-01-01 05:00:00" "2013-01-01 05:00:00" "2013-01-01 05:00:00"
## [4] "2013-01-01 05:00:00" "2013-01-01 06:00:00" "2013-01-01 05:00:00"
```

```
class(flights$time_hour)
```

```
## [1] "character"
```

Entretanto, a classe de `flights$time_hour` é caracter, o que nos impossibilita trabalhar com datas de maneira adequada. Uma alternativa, é utilizar a biblioteca `lubridate`. Para isso, execute o comando abaixo para instalá-la.

```
install.packages("lubridate")
```

Em seguida, basta carregar a biblioteca e utilizar as funções que fazem conversão de caracteres em data e manipulações relacionadas a este tipo de dado. Abaixo, adicionamos períodos de tempos à uma data (anos, meses, dias), obtemos a diferença entre duas datas e selecionamos a unidade de tempo para exibir essa diferença.

```
library(lubridate)
```

```
## Carregando pacotes exigidos: timechange
```

```
##
## Attaching package: 'lubridate'
```

```
## The following objects are masked from 'package:base':
##
##     date, intersect, setdiff, union
```

```
data <- "25/12/92"
class(data)
```

```
## [1] "character"
```

```
data <- dmy(data)
class(data)
```

```
## [1] "Date"
```

```
year(data)
```

```
## [1] 1992
```

```
month(data)
```

```
## [1] 12
```

```
day(data)
```

```
## [1] 25
```

```
# adicionar 10 anos a uma data
data + years(10)
```

```
## [1] "2002-12-25"
```

```
# adicionar 10 anos e 5 meses a uma data
data + years(10) + months(5)
```

```
## [1] "2003-05-25"
```

```
# adicionar 10 anos, 5 meses e 7 dias a uma data
data + years(10) + months(5) + days(7)
```

```
## [1] "2003-06-01"
```

```
# obter a diferença de duas datas em dias
interval(data, today()) / years(1)
```

```
## [1] 31.04918
```

```
# obter a diferença de duas datas em dias
interval(data, today()) / days(1)
```

```
## [1] 11340
```

Este pacote nos permite trabalhar com data e hora em uma mesma variável. Note que agora a data está representada no formato MM/DD/AAAA, além de hora, minutos e segundos.

```
data <- "12/25/92 10:07:35"
class(data)
```

```
## [1] "character"
```

```
data <- mdy_hms(data)
class(data)
```

```
## [1] "POSIXct" "POSIXt"
```

```
year(data)
```

```
## [1] 1992
```

```
hour(data)
```

```
## [1] 10
```

```
minute(data)
```

```
## [1] 7
```

```
second(data)
```

```
## [1] 35
```

Com isso, podemos coverter a coluna `flights$time_hour` para o tipo de dados `date`.

```
flights$time_hour <- ymd_hms(flights$time_hour)
```

Agora, todas as colunas de `flights` estão com os tipos de dados corretos.

```
str(flights)
```

```
## 'data.frame':    336776 obs. of  20 variables:
##  $ X             : int  1 2 3 4 5 6 7 8 9 10 ...
##  $ year          : int  2013 2013 2013 2013 2013 2013 2013 2013 2013 2013 ...
##  $ month         : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ day           : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ dep_time      : int  517 533 542 544 554 554 555 557 557 558 ...
##  $ sched_dep_time: int  515 529 540 545 600 558 600 600 600 600 ...
##  $ dep_delay     : int  2 4 2 -1 -6 -4 -5 -3 -3 -2 ...
##  $ arr_time      : int  830 850 923 1004 812 740 913 709 838 753 ...
##  $ sched_arr_time: int  819 830 850 1022 837 728 854 723 846 745 ...
##  $ arr_delay     : int  11 20 33 -18 -25 12 19 -14 -8 8 ...
##  $ carrier       : Factor w/ 16 levels "9E","AA","AS",..: 12 12 2 4 5 12 4 6 4 2 ..
##  $ flight        : int  1545 1714 1141 725 461 1696 507 5708 79 301 ...
##  $ tailnum       : chr  "N14228" "N24211" "N619AA" "N804JB" ...
##  $ origin        : Factor w/ 3 levels "EWR","JFK","LGA": 1 3 2 2 3 1 1 3 2 3 ...
##  $ dest          : Factor w/ 105 levels "ABQ","ACK","ALB",..: 44 44 59 13 5 70 36 43
##  $ air_time      : int  227 227 160 183 116 150 158 53 140 138 ...
##  $ distance      : int  1400 1416 1089 1576 762 719 1065 229 944 733 ...
##  $ hour          : int  5 5 5 5 6 5 6 6 6 6 ...
##  $ minute        : int  15 29 40 45 0 58 0 0 0 0 ...
##  $ time_hour     : POSIXct, format: "2013-01-01 05:00:00" "2013-01-01 05:00:00" ...
```

3.1 Análise descritiva

Realizar uma analise descritiva é fundamental para compreender, de forma resumida, a informação contida nos dados.

Uma função que resume de maneira "inteligente" todas as colunas de um data frame é a `summary`. É "inteligente" porque, a forma como o resumo é feito depente do tipo de cada coluna da tabela. Em `flights` há colunas numéricas, fatores, caracter e data.

```
summary(flights)
```

```
##        X               year          month             day        
##  Min.   :     1   Min.   :2013   Min.   : 1.000   Min.   : 1.00  
##  1st Qu.: 84195   1st Qu.:2013   1st Qu.: 4.000   1st Qu.: 8.00
```

```
##  Median :168389   Median :2013   Median : 7.000   Median :16.00
##  Mean   :168389   Mean   :2013   Mean   : 6.549   Mean   :15.71
##  3rd Qu.:252582   3rd Qu.:2013   3rd Qu.:10.000   3rd Qu.:23.00
##  Max.   :336776   Max.   :2013   Max.   :12.000   Max.   :31.00
##
##     dep_time    sched_dep_time   dep_delay          arr_time    sched_arr_time
##  Min.   :   1   Min.   : 106   Min.   : -43.00   Min.   :   1   Min.   :   1
##  1st Qu.: 907   1st Qu.: 906   1st Qu.:  -5.00   1st Qu.:1104   1st Qu.:1124
##  Median :1401   Median :1359   Median :  -2.00   Median :1535   Median :1556
##  Mean   :1349   Mean   :1344   Mean   :  12.64   Mean   :1502   Mean   :1536
##  3rd Qu.:1744   3rd Qu.:1729   3rd Qu.:  11.00   3rd Qu.:1940   3rd Qu.:1945
##  Max.   :2400   Max.   :2359   Max.   :1301.00   Max.   :2400   Max.   :2359
##  NA's   :8255                  NA's   :8255      NA's   :8713
##    arr_delay          carrier          flight       tailnum
##  Min.   : -86.000   UA     :58665   Min.   :   1   Length:336776
##  1st Qu.: -17.000   B6     :54635   1st Qu.: 553   Class :character
##  Median :  -5.000   EV     :54173   Median :1496   Mode  :character
##  Mean   :   6.895   DL     :48110   Mean   :1972
##  3rd Qu.:  14.000   AA     :32729   3rd Qu.:3465
##  Max.   :1272.000   MQ     :26397   Max.   :8500
##  NA's   :9430       (Other):62067
##  origin            dest           air_time        distance         hour
##  EWR:120835   ORD    : 17283   Min.   : 20.0   Min.   :  17   Min.   : 1.00
##  JFK:111279   ATL    : 17215   1st Qu.: 82.0   1st Qu.: 502   1st Qu.: 9.00
##  LGA:104662   LAX    : 16174   Median :129.0   Median : 872   Median :13.00
##               BOS    : 15508   Mean   :150.7   Mean   :1040   Mean   :13.18
##               MCO    : 14082   3rd Qu.:192.0   3rd Qu.:1389   3rd Qu.:17.00
##               CLT    : 14064   Max.   :695.0   Max.   :4983   Max.   :23.00
##               (Other):242450   NA's   :9430
##      minute        time_hour
##  Min.   : 0.00   Min.   :2013-01-01 05:00:00.00
##  1st Qu.: 8.00   1st Qu.:2013-04-04 13:00:00.00
##  Median :29.00   Median :2013-07-03 10:00:00.00
##  Mean   :26.23   Mean   :2013-07-03 05:02:36.49
##  3rd Qu.:44.00   3rd Qu.:2013-10-01 07:00:00.00
##  Max.   :59.00   Max.   :2013-12-31 23:00:00.00
##
```

Vamos obter a média de atrasos por aeroporto de origem. Antes, vamos verificar quantos aeroportos de origem existem na base.

```
unique(flights$origin)
```

```
## [1] EWR LGA JFK
## Levels: EWR JFK LGA
```

Há quantos voos registrados saindo de cada aeroporto?

```
table(flights$origin)
```

```
##
##    EWR    JFK    LGA
## 120835 111279 104662
```

Exercício: qual o nome dos aeroportos cujos códigos FAA estão listados acima? (Dica: fazer merge com `airports`).

Agora, vamos calcular a média de atraso geral para voos que partiram de "JFK".

```
mean(flights$dep_delay[flights$origin == "JFK"])
```

```
## [1] NA
```

Note que existem dados faltantes (do tipo `NA`) na coluna `dep_delay`. Podemos desconsiderar esses dados no cálculo da média.

```
mean(flights$dep_delay[flights$origin == "JFK"], na.rm = TRUE)
```

```
## [1] 12.11216
```

Podemos utilizar a função `tapply` para obter o resultado de uma função aplicada de acordo com certos grupos. Por exemplo, para obter a média de atraso dos voos de cada um dos aeroportos de origem, use o comando abaixo.

```
tapply(flights$dep_delay, flights$origin, mean, na.rm = TRUE)
```

```
##      EWR      JFK      LGA
## 15.10795 12.11216 10.34688
```

Para arredondar números, podemos usar a função `round`, informando quantas casas decimais devem ser consideradas.

```
round(tapply(flights$dep_delay, flights$origin, mean, na.rm = TRUE), 2)
```

```
##   EWR   JFK   LGA
## 15.11 12.11 10.35
```

Podemos fazer o mesmo considerando os aeroportos de destino.

```
unique(flights$dest)
```

```
##   [1] IAH MIA BQN ATL ORD FLL IAD MCO PBI TPA LAX SFO DFW BOS LAS MSP DTW RSW
##  [19] SJU PHX BWI CLT BUF DEN SNA MSY SLC XNA MKE SEA ROC SYR SRQ RDU CMH JAX
##  [37] CHS MEM PIT SAN DCA CLE STL MYR JAC MDW HNL BNA AUS BTV PHL STT EGE AVL
##  [55] PWM IND SAV CAK HOU LGB DAY ALB BDL MHT MSN GSO CVG BUR RIC GSP GRR MCI
##  [73] ORF SAT SDF PDX SJC OMA CRW OAK SMF TUL TYS OKC PVD DSM PSE BHM CAE HDN
##  [91] BZN MTJ EYW PSP ACK BGR ABQ ILM MVY SBN LEX CHO TVC ANC LGA
## 105 Levels: ABQ ACK ALB ANC ATL AUS AVL BDL BGR BHM BNA BOS BQN BTV BUF ... XNA
```

```
round(tapply(flights$arr_delay, flights$origin, mean, na.rm = TRUE), 2)
```

```
##  EWR  JFK  LGA
## 9.11 5.55 5.78
```

Saber somente a média de uma meida não é suficiente, devemos obter outras estatísticas, como a mediana, desvio padrão e variância, por exemplo.

```
tapply(flights$dep_delay, flights$origin, median, na.rm = TRUE)
```

```
## EWR JFK LGA
##  -1  -1  -3
```

```
tapply(flights$dep_delay, flights$origin, sd, na.rm = TRUE)
```

```
##      EWR      JFK      LGA
## 41.32370 39.03507 39.99302
```

```
tapply(flights$dep_delay, flights$origin, var, na.rm = TRUE)
```

```
##      EWR      JFK      LGA
## 1707.649 1523.737 1599.442
```

Podemos combinar todos esses resultados acima em uma única tabela, usando o comoando `cbind`. Abaixo, acrescentamos ainda os valores mínimo e máximo de atraso na partida observado em cada aerporto.

```
cbind(Media = tapply(flights$dep_delay, flights$origin, mean, na.rm = TRUE),
      Mediana = tapply(flights$dep_delay, flights$origin, median, na.rm = TRUE),
      Minimo = tapply(flights$dep_delay, flights$origin, min, na.rm = TRUE),
      Maximo = tapply(flights$dep_delay, flights$origin, max, na.rm = TRUE),
      Desvio_padrao = tapply(flights$dep_delay, flights$origin, sd, na.rm = TRUE),
      Variancia = tapply(flights$dep_delay, flights$origin, var, na.rm = TRUE))
```

```
##        Media Mediana Minimo Maximo Desvio_padrao Variancia
## EWR 15.10795      -1    -25   1126      41.32370  1707.649
## JFK 12.11216      -1    -43   1301      39.03507  1523.737
## LGA 10.34688      -3    -33    911      39.99302  1599.442
```

Além disso, podemos construir gráficos, para analisar os dados de forma visual. Abaixo, criamos histogramas do atrado na partida de cada um dos três aeroportos de Nova York.

```
hist(flights$dep_delay[flights$origin == "JFK"], main="JFK")
```

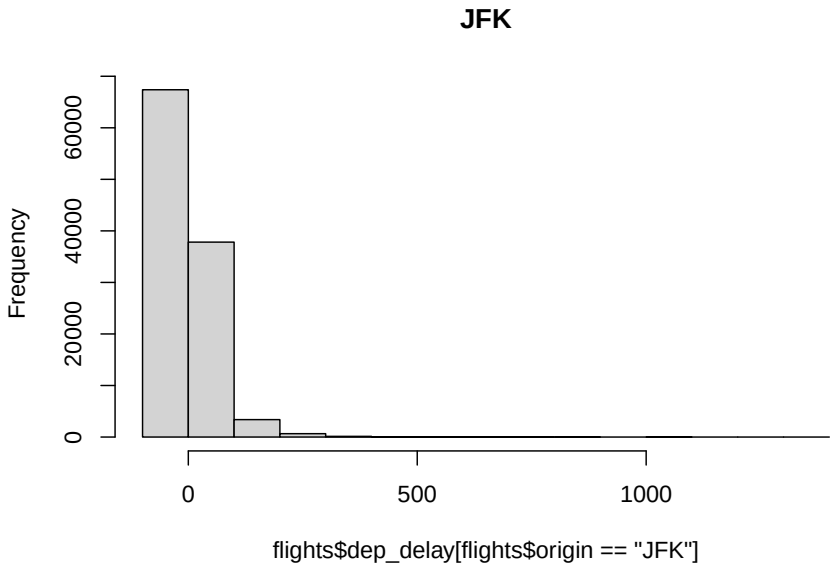


```
hist(flights$dep_delay[flights$origin == "LGA"], main="LGA")
```

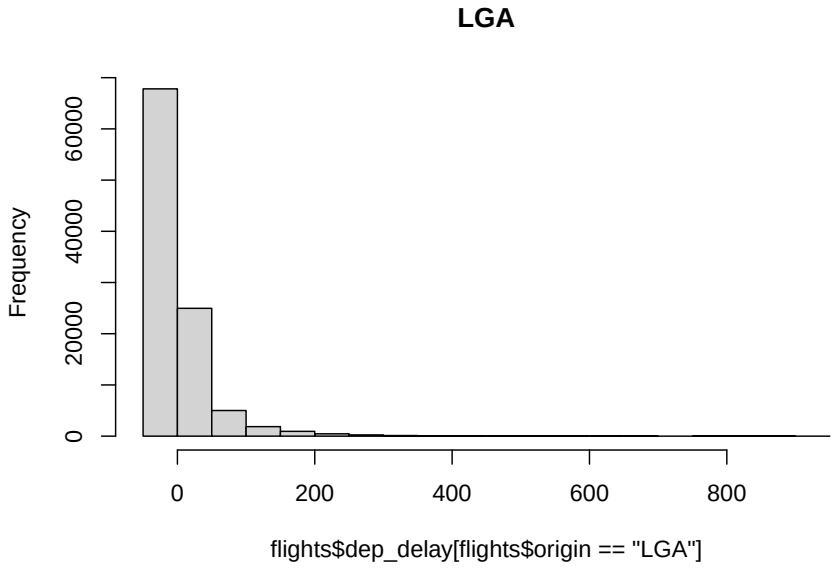


```
hist(flights$dep_delay[flights$origin == "EWR"], main="EWR")
```

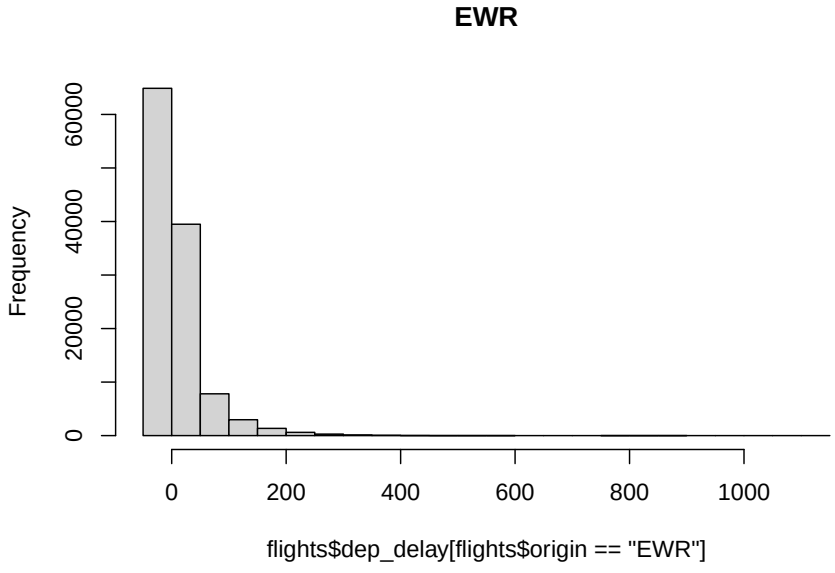

Os três gráficos podem ser exibidos de uma única vez se usarmos a opção `mfrow`, que permite definir o número de linhas e colunas do grid para plotar os gráficos.

```
par(mfrow=c(1,3))

hist(flights$dep_delay[flights$origin == "JFK"], main="JFK")

hist(flights$dep_delay[flights$origin == "LGA"], main="LGA")

hist(flights$dep_delay[flights$origin == "EWR"], main="EWR")
```

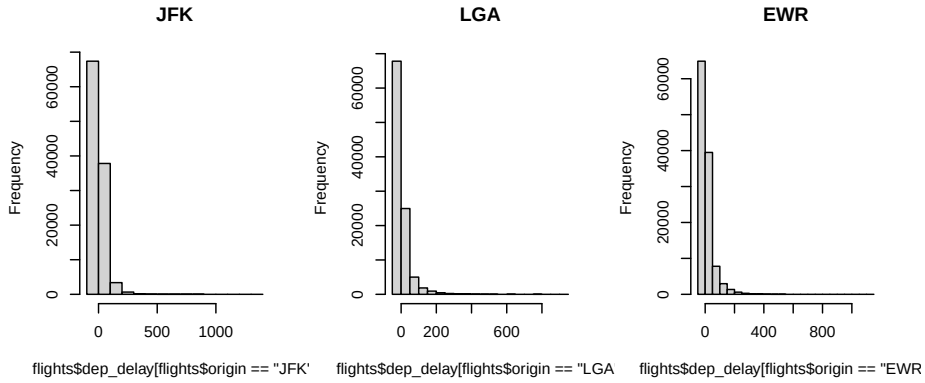

3.2 Lista de exercicios

1. Importe no `R` a planilha de dados correspondente ao seu projeto aplicado.
2. Verifique se alguma coluna deve ser transformada para um tipo de dados mais adequado.
3. Obtenha estatísticas descritivas dos dados.

Chapter 4

O pacote `tidyverse`

> Este capítulo foi baseado no livro R for Data Science, que atualmente está sendo traduzido para o português brasileiro através de um grupo de pessoas voluntárias (mais detalhes aqui).

`tidyverse` é uma coleção de bibliotecas criadas para o universo de data science. Todos os pacotes 'tidyverse' possuem a mesma gramática, estrutura de dados e filosofia:

Veja todos os pacotes disponíveis em: https://www.tidyverse.org/

Vamos instalar o pacote `tidyverse`:

```
install.packages("tidyverse")
```

E carregar a biblioteca:

```
library(tidyverse)
```

4.1 O operador pipe (%>%) da library `magrittr`

Atalho no teclado: `Ctrl + Shift + M`

Passa o objeto do lado esquerdo como primeiro argumento (ou .argumento) da função do lado direito:

- `x %>% f(y)` é equivalente a f(**x**,y)
- `y %>% f(x, .,z)` é equivalente a f(x,**y**,z)

Na prática, vamos supor que queremos somar todos os elementos do `vetor` e em seguida tirar a raiz quadrada desta soma:

```
vetor <- c(20,40,60,80,200)

#raiz da soma
sqrt(sum(vetor))
```

```
## [1] 20
```

Usando o pipe:

```
vetor %>% sum() %>% sqrt()
```

```
## [1] 20
```

4.2 Transformação de Dados com `dplyr`

As cinco principais funções do `dplyr` são:

- `filter()`
- `arrange()`
- `select()`
- `mutate()`
- `summarize()`

Todos os verbos funcionam de maneira similar:

1. O primeiro argumento é um data frame
2. Os próximos argumentos descrevem o que fazer com o data frame
3. O resultado é um novo data frame

4.3 Filtrando linhas com `filter()`

Vamos voltar a utilizar a base de dados flights:

```
flights <- read.csv("flights.csv")
```

Sem pipe:

```
filter(flights, month == 1, day == 1)
```

```
## # A tibble: 842 x 19
##     year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1  2013     1     1      517            515         2      830            819
##  2  2013     1     1      533            529         4      850            830
##  3  2013     1     1      542            540         2      923            850
##  4  2013     1     1      544            545        -1     1004           1022
##  5  2013     1     1      554            600        -6      812            837
##  6  2013     1     1      554            558        -4      740            728
##  7  2013     1     1      555            600        -5      913            854
##  8  2013     1     1      557            600        -3      709            723
##  9  2013     1     1      557            600        -3      838            846
## 10  2013     1     1      558            600        -2      753            745
## # i 832 more rows
## # i 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

Com pipe:

```
flights %>% filter(month == 1, day == 1)
```

```
## # A tibble: 842 x 19
##     year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1  2013     1     1      517            515         2      830            819
##  2  2013     1     1      533            529         4      850            830
##  3  2013     1     1      542            540         2      923            850
##  4  2013     1     1      544            545        -1     1004           1022
##  5  2013     1     1      554            600        -6      812            837
##  6  2013     1     1      554            558        -4      740            728
##  7  2013     1     1      555            600        -5      913            854
##  8  2013     1     1      557            600        -3      709            723
##  9  2013     1     1      557            600        -3      838            846
## 10  2013     1     1      558            600        -2      753            745
## # i 832 more rows
## # i 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

Atrubuindo e imprimindo:

```
# Para atribuir e imprimir de uma só vez, coloque
# parênteses em volta da atribuição (os dois espaços
# depois dos parênteses abaixo não são necessários).

(  jan1 <- flights %>% filter(month == 1, day == 1)  )
```

```
## # A tibble: 842 x 19
##     year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1  2013     1     1      517            515         2      830            819
##  2  2013     1     1      533            529         4      850            830
##  3  2013     1     1      542            540         2      923            850
##  4  2013     1     1      544            545        -1     1004           1022
##  5  2013     1     1      554            600        -6      812            837
##  6  2013     1     1      554            558        -4      740            728
##  7  2013     1     1      555            600        -5      913            854
##  8  2013     1     1      557            600        -3      709            723
##  9  2013     1     1      557            600        -3      838            846
## 10  2013     1     1      558            600        -2      753            745
## # i 832 more rows
## # i 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

Podemos utilizar os operadores lógicos aprendidos nas primeiras aulas para filtrar aqui também.

Por exemplo, vamos filtar somente as observações que **não** são `NA` na coluna `arr_delay`:

```
flights %>% filter(!is.na(arr_delay))
```

```
## # A tibble: 327,346 x 19
##     year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1  2013     1     1      517            515         2      830            819
##  2  2013     1     1      533            529         4      850            830
##  3  2013     1     1      542            540         2      923            850
##  4  2013     1     1      544            545        -1     1004           1022
##  5  2013     1     1      554            600        -6      812            837
##  6  2013     1     1      554            558        -4      740            728
##  7  2013     1     1      555            600        -5      913            854
##  8  2013     1     1      557            600        -3      709            723
##  9  2013     1     1      557            600        -3      838            846
## 10  2013     1     1      558            600        -2      753            745
## # i 327,336 more rows
## # i 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

Origem = Kennedy ou Newark, Destino = Los Angeles:

```
flights %>% filter(origin %in% c("JFK", "EWR"), dest == "LAX")
```

```
## # A tibble: 16,174 x 19
##     year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1  2013     1     1      558            600        -2      924            917
##  2  2013     1     1      628            630        -2     1016            947
##  3  2013     1     1      658            700        -2     1027           1025
##  4  2013     1     1      702            700         2     1058           1014
##  5  2013     1     1      743            730        13     1107           1100
##  6  2013     1     1      828            823         5     1150           1143
##  7  2013     1     1      829            830        -1     1152           1200
##  8  2013     1     1      856            900        -4     1226           1220
##  9  2013     1     1      859            900        -1     1223           1225
## 10  2013     1     1      921            900        21     1237           1227
## # i 16,164 more rows
## # i 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
```

```
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

4.4 Arranjando linhas com `arrange()`

Organizando os dados segundo a ordem crescente da coluna `dep_delay`:

```
flights %>% arrange(dep_delay)
```

```
## # A tibble: 336,776 x 19
##     year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1  2013    12     7     2040           2123       -43       40           2352
##  2  2013     2     3     2022           2055       -33     2240           2338
##  3  2013    11    10     1408           1440       -32     1549           1559
##  4  2013     1    11     1900           1930       -30     2233           2243
##  5  2013     1    29     1703           1730       -27     1947           1957
##  6  2013     8     9      729            755       -26     1002            955
##  7  2013    10    23     1907           1932       -25     2143           2143
##  8  2013     3    30     2030           2055       -25     2213           2250
##  9  2013     3     2     1431           1455       -24     1601           1631
## 10  2013     5     5      934            958       -24     1225           1309
## # i 336,766 more rows
## # i 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

Agora usando a ordem decrescente:

```
flights %>% arrange(desc(dep_delay))
```

```
## # A tibble: 336,776 x 19
##     year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1  2013     1     9      641            900      1301     1242           1530
##  2  2013     6    15     1432           1935      1137     1607           2120
##  3  2013     1    10     1121           1635      1126     1239           1810
##  4  2013     9    20     1139           1845      1014     1457           2210
##  5  2013     7    22      845           1600      1005     1044           1815
##  6  2013     4    10     1100           1900       960     1342           2211
##  7  2013     3    17     2321            810       911      135           1020
##  8  2013     6    27      959           1900       899     1236           2226
##  9  2013     7    22     2257            759       898      121           1026
## 10  2013    12     5      756           1700       896     1058           2020
## # i 336,766 more rows
## # i 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

Se você fornecer mais de uma coluna, as demais colunas serão usadas sucessivamente para decidir os empates:

```
flights %>% arrange(desc(month), day)
```

```
## # A tibble: 336,776 x 19
##     year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1  2013    12     1       13           2359        14      446            445
##  2  2013    12     1       17           2359        18      443            437
##  3  2013    12     1      453            500        -7      636            651
##  4  2013    12     1      520            515         5      749            808
##  5  2013    12     1      536            540        -4      845            850
##  6  2013    12     1      540            550       -10     1005           1027
##  7  2013    12     1      541            545        -4      734            755
##  8  2013    12     1      546            545         1      826            835
##  9  2013    12     1      549            600       -11      648            659
## 10  2013    12     1      550            600       -10      825            854
## # i 336,766 more rows
## # i 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

4.5 Selecionando colunas com select()

Vamos supor que eu só queira utilizar colunas específicas da minha base: `carrier`, `year`, `month` e `day`

```
flights %>% select(carrier, year, month, day)
```

```
## # A tibble: 336,776 x 4
##    carrier  year month   day
##    <chr>   <int> <int> <int>
##  1 UA       2013     1     1
##  2 UA       2013     1     1
##  3 AA       2013     1     1
##  4 B6       2013     1     1
##  5 DL       2013     1     1
##  6 UA       2013     1     1
##  7 B6       2013     1     1
##  8 EV       2013     1     1
##  9 B6       2013     1     1
## 10 AA       2013     1     1
## # i 336,766 more rows
```

Selecionando todas as colunas, MENOS a coluna `year`:

```
flights %>% select(-year)
```

```
## # A tibble: 336,776 x 18
##    month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1     1     1      517            515         2      830            819
##  2     1     1      533            529         4      850            830
##  3     1     1      542            540         2      923            850
##  4     1     1      544            545        -1     1004           1022
##  5     1     1      554            600        -6      812            837
##  6     1     1      554            558        -4      740            728
##  7     1     1      555            600        -5      913            854
##  8     1     1      557            600        -3      709            723
##  9     1     1      557            600        -3      838            846
## 10     1     1      558            600        -2      753            745
## # i 336,766 more rows
## # i 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

`everything()` é útil para mover as colunas de lugar:

```
flights %>% select(carrier, origin, everything())
```

```
## # A tibble: 336,776 x 19
##    carrier origin  year month   day dep_time sched_dep_time dep_delay arr_time
##    <chr>   <chr>  <int> <int> <int>    <int>          <int>     <dbl>    <int>
##  1 UA      EWR     2013     1     1      517            515         2      830
##  2 UA      LGA     2013     1     1      533            529         4      850
##  3 AA      JFK     2013     1     1      542            540         2      923
##  4 B6      JFK     2013     1     1      544            545        -1     1004
##  5 DL      LGA     2013     1     1      554            600        -6      812
##  6 UA      EWR     2013     1     1      554            558        -4      740
##  7 B6      EWR     2013     1     1      555            600        -5      913
##  8 EV      LGA     2013     1     1      557            600        -3      709
##  9 B6      JFK     2013     1     1      557            600        -3      838
## 10 AA      LGA     2013     1     1      558            600        -2      753
## # i 336,766 more rows
## # i 10 more variables: sched_arr_time <int>, arr_delay <dbl>, flight <int>,
## #   tailnum <chr>, dest <chr>, air_time <dbl>, distance <dbl>, hour <dbl>,
## #   minute <dbl>, time_hour <dttm>
```

Também podemos renomear uma coluna dentro do select:

```
#renomeando a coluna year para "ano":

flights %>% select("ano" = year, month, day)
```

```
## # A tibble: 336,776 x 3
##      ano month   day
##    <int> <int> <int>
##  1  2013     1     1
##  2  2013     1     1
##  3  2013     1     1
##  4  2013     1     1
##  5  2013     1     1
##  6  2013     1     1
##  7  2013     1     1
##  8  2013     1     1
##  9  2013     1     1
## 10  2013     1     1
## # i 336,766 more rows
```

Combinando `filter()`, `select()` e `arrange()`:

Suponha que nosso objetivo seja verificar qual a companhia aérea que mais atrasa nos vôos entre JFK e LAX:

```
flights %>%
    filter(origin == "JFK", dest == "LAX") %>%
    select(carrier, dep_delay) %>%
    arrange(desc(dep_delay))
```

```
## # A tibble: 11,262 x 2
##    carrier dep_delay
##    <chr>       <dbl>
##  1 DL            800
##  2 VX            634
##  3 VX            434
##  4 VX            413
##  5 VX            392
##  6 UA            364
##  7 AA            345
##  8 AA            334
##  9 VX            322
## 10 AA            321
## # i 11,252 more rows
```

4.6 Criando variáveis (colunas) com `mutate()`

Queremos criar uma variável que mostre a velocidade de cada voo:

```
flights %>%
    select(year:day, flight,  distance, air_time) %>%
    mutate(speed = distance / (air_time / 60))
```

```
## # A tibble: 336,776 x 7
##     year month   day flight distance air_time speed
##    <int> <int> <int>  <int>    <dbl>    <dbl> <dbl>
##  1  2013     1     1   1545     1400      227  370.
##  2  2013     1     1   1714     1416      227  374.
##  3  2013     1     1   1141     1089      160  408.
##  4  2013     1     1    725     1576      183  517.
##  5  2013     1     1    461      762      116  394.
##  6  2013     1     1   1696      719      150  288.
##  7  2013     1     1    507     1065      158  404.
##  8  2013     1     1   5708      229       53  259.
##  9  2013     1     1     79      944      140  405.
## 10  2013     1     1    301      733      138  319.
## # i 336,766 more rows
```

Note que você também pode se referir às variáveis que criou:

```
flights %>%
    select(year:day, flight,  distance, air_time) %>%
    mutate(hours = air_time / 60,
           speed = distance / hours)
```

```
## # A tibble: 336,776 x 8
##     year month   day flight distance air_time hours speed
##    <int> <int> <int>  <int>    <dbl>    <dbl> <dbl> <dbl>
##  1  2013     1     1   1545     1400      227 3.78   370.
##  2  2013     1     1   1714     1416      227 3.78   374.
##  3  2013     1     1   1141     1089      160 2.67   408.
##  4  2013     1     1    725     1576      183 3.05   517.
##  5  2013     1     1    461      762      116 1.93   394.
##  6  2013     1     1   1696      719      150 2.5    288.
##  7  2013     1     1    507     1065      158 2.63   404.
##  8  2013     1     1   5708      229       53 0.883  259.
##  9  2013     1     1     79      944      140 2.33   405.
## 10  2013     1     1    301      733      138 2.3    319.
## # i 336,766 more rows
```

4.7 summarise() colapsa a tabela toda em apenas uma linha

Vamos calcular o atraso médio de decolagem e a quantidade total de voos:

```
flights %>%
    filter(!is.na(dep_delay)) %>%
    summarise(mean_delay = mean(dep_delay), number_of_flights = n())
```

```
## # A tibble: 1 x 2
##   mean_delay number_of_flights
##        <dbl>             <int>
## 1       12.6            328521
```

4.8 group_by() muda a "unidade de análise" de toda a tabela para os grupos definidos

Vamos calcular o atraso médio de decolagem e a quantidade total de voos, mas agora analisando por companhia aérea:

```
flights %>%
    filter(!is.na(dep_delay)) %>%
    group_by(carrier) %>%
    summarise(mean_delay = mean(dep_delay), number_of_flights = n())
```

```
## # A tibble: 16 x 3
##    carrier mean_delay number_of_flights
##    <chr>        <dbl>             <int>
##  1 9E           16.7              17416
##  2 AA            8.59             32093
##  3 AS            5.80               712
##  4 B6           13.0              54169
##  5 DL            9.26             47761
##  6 EV           20.0              51356
##  7 F9           20.2                682
##  8 FL           18.7               3187
##  9 HA            4.90               342
## 10 MQ           10.6              25163
## 11 OO           12.6                 29
## 12 UA           12.1              57979
## 13 US            3.78             19873
## 14 VX           12.9               5131
```

```
## 15 WN           17.7              12083
## 16 YV           19.0                545
```

4.8.1 DESAFIO:

Para cada destino, calcule: a (1) distância média dos voos e (2) o tempo de atraso médio na decolagem e (3) o número de voos na base e mostre tudo numa planilha só.

Chapter 5

Vizualização com ggplot

> Este capítulo foi escrito baseado em Cotton (2013) e o conteúdo apresentado aqui foi usado como base para o minicurso "R para não-programadores" que ministrei junto com a prof. Marina Bicudo.

`ggplot2` é uma biblioteca popular para criação de gráficos em R.

O `ggplot2` funciona seguindo o conceito de "grammar of graphics" (gramática dos gráficos). Você constrói um gráfico camada por camada, adicionando elementos conforme necessário.

Comece criando um objeto `ggplot` com a função `ggplot()`. Essa função recebe o conjunto de dados que você deseja visualizar, por exemplo os dados de voos do pacote `nycflights`.

Vamos supor que nosso objetivo seja entender a relação entre distância do voo e atraso. Para isso, utilizaremos um **gráfico de dispersão**.

5.1 Criando um objeto ggplot

Para começar, vamos criar um objeto ggplot utilizando a base de dados `flights`, calculando o atraso médio dos voos por destino.

```
library(tidyverse)

atrasos <- flights %>%
    filter(!is.na(distance), !is.na(arr_delay)) %>%
    group_by(dest) %>%
    summarise(distance = mean(distance),
              delay = mean(arr_delay))
head(atrasos)
```

```
## # A tibble: 6 x 3
##   dest  distance delay
##   <chr>    <dbl> <dbl>
## 1 ABQ      1826   4.38
## 2 ACK       199   4.85
## 3 ALB       143  14.4
## 4 ANC      3370  -2.5
## 5 ATL       757. 11.3
## 6 AUS      1514.  6.02
```

```
atrasos %>% ggplot()
```


Observe que o objeto `ggplot` gerado representa apenas uma tela em branco, pois, dos três componentes básicos, apenas a base de dados (atrasos) foi especificada.

5.2 Gráfico de Dispersão

Nosso objetivo é criar um gráfico de dispersão, utilizando a geometria (`geom_point`). Vamos mapear as variáveis (x e y) dentro do componente de estética (aesthetics):

```
atrasos %>%
  ggplot(aes(x = distance, y = delay)) +
  geom_point(color = "red")
```

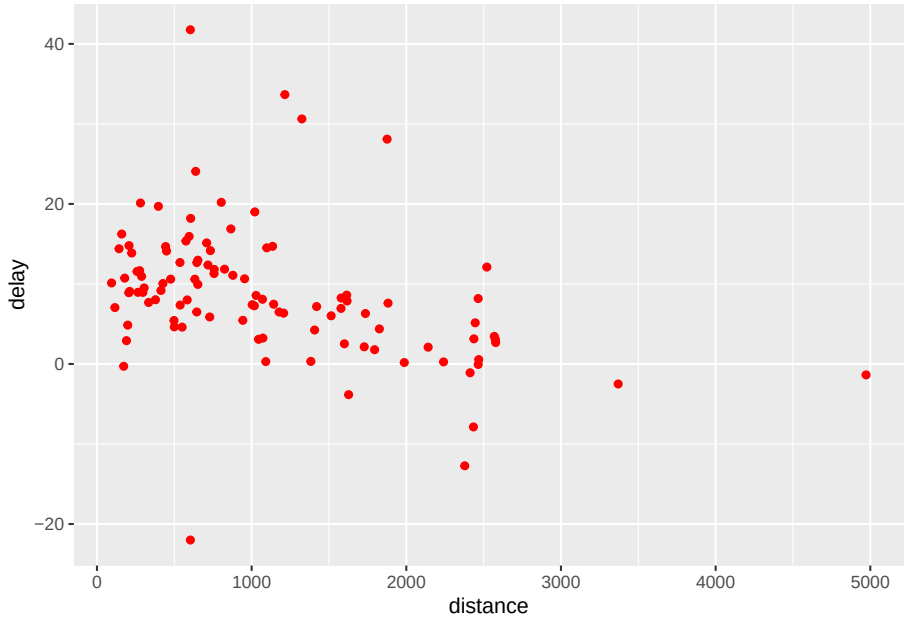

Podemos criar uma variável que indica se houve atraso ou adiantamento, ajustando a cor dos pontos de acordo com essa nova variável:

```
atrasos %>%
  mutate(sinal = ifelse(delay > 0, "- atrasou", "+ adiantou")) %>%
  ggplot(aes(x = distance, y = delay)) +
  geom_point(aes(color = sinal))
```

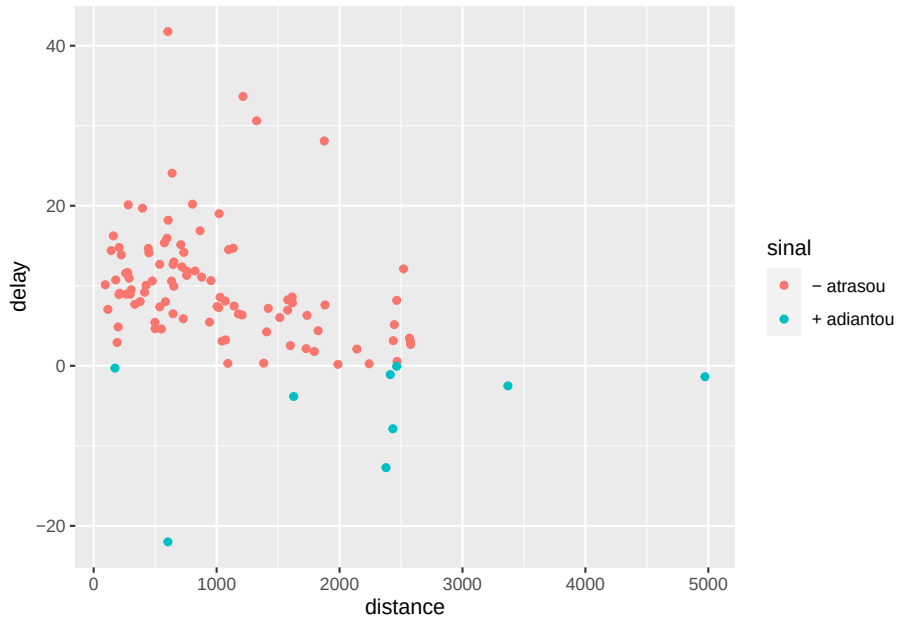

Além disso, adicionaremos uma camada (*layer*) com a linha de tendência (equação da reta):

```
atrasos %>%
  mutate(sinal = ifelse(delay > 0, "atrasou", "não atrasou")) %>%
  ggplot(aes(x = distance, y = delay)) +
  geom_point(aes(color = sinal)) +
  geom_smooth(method = "lm",
              se = FALSE,
              color = "black")
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

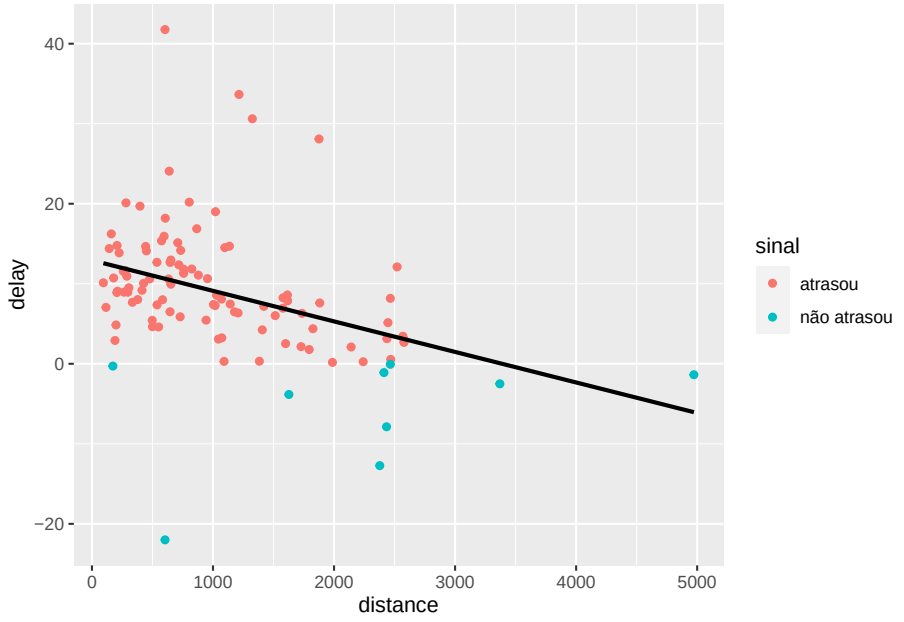

Vamos agora personalizar o título do gráfico e dos eixos:

```
atrasos %>%
  mutate(sinal = ifelse(delay > 0, "Atrasou", "Não atrasou")) %>%
  ggplot(aes(x = distance, y = delay)) +
  geom_point(aes(color = sinal)) +
  geom_smooth(method = "lm",
              se = FALSE,
              color = "black") +
  labs(title = "Distância x Atrasos (vôos partindo de NY)",
       x = "Distância (em milhas)",
       y = "Atraso na decolagem (em minutos)",
       color = "")
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

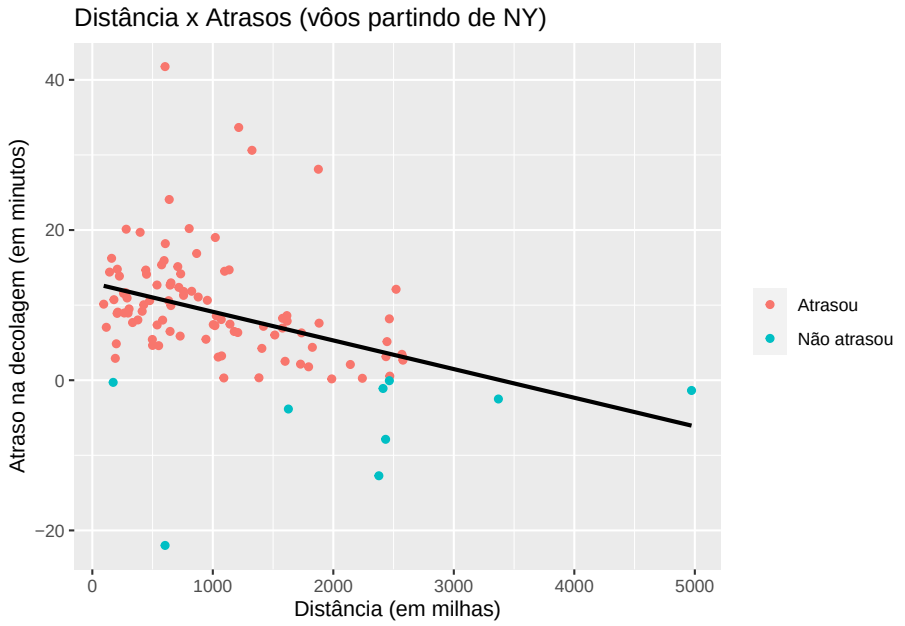

Por fim, podemos ajustar a aparência geral do gráfico:

```
atrasos %>%
  mutate(sinal = ifelse(delay > 0, "Atrasou", "Não atrasou")) %>%
  ggplot(aes(x = distance, y = delay)) +
  geom_point(aes(color = sinal)) +
  geom_smooth(method = "lm",
              se = FALSE,
              color = "black") +
  labs(title = "Distância x Atrasos (vôos partindo de NY)",
       x = "Distância (em milhas)",
       y = "Atraso na decolagem (em minutos)",
       color = "") +
  theme_minimal()
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

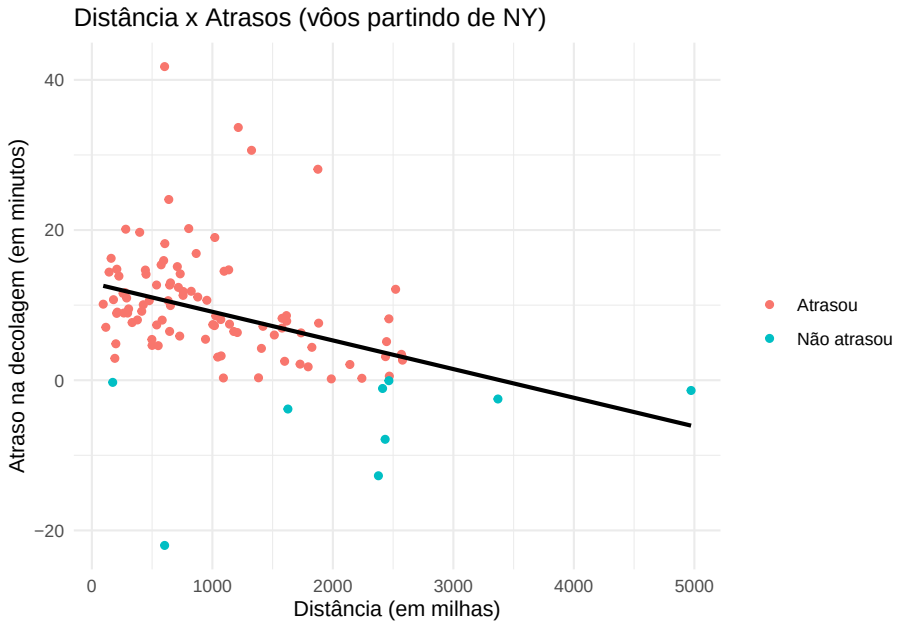

5.3 Gráfico de Colunas

Vamos supor agora que nosso interesse seja criar um gráfico de colunas comparando o atraso médio dos 5 principais destinos que mais sofrem atrasos:

```
top_5 <- atrasos %>% top_n(5, delay)
top_5
```

```
## # A tibble: 5 x 3
##   dest  distance delay
##   <chr>    <dbl> <dbl>
## 1 CAE       604.  41.8
## 2 JAC      1876.  28.1
## 3 OKC      1325   30.6
## 4 TUL      1215   33.7
## 5 TYS       638.  24.1
```

Construindo nosso gráfico de colunas utilizando `geom_col()`:

```
top_5 %>%
  ggplot(aes(x = dest, y = delay)) +
  geom_col()
```

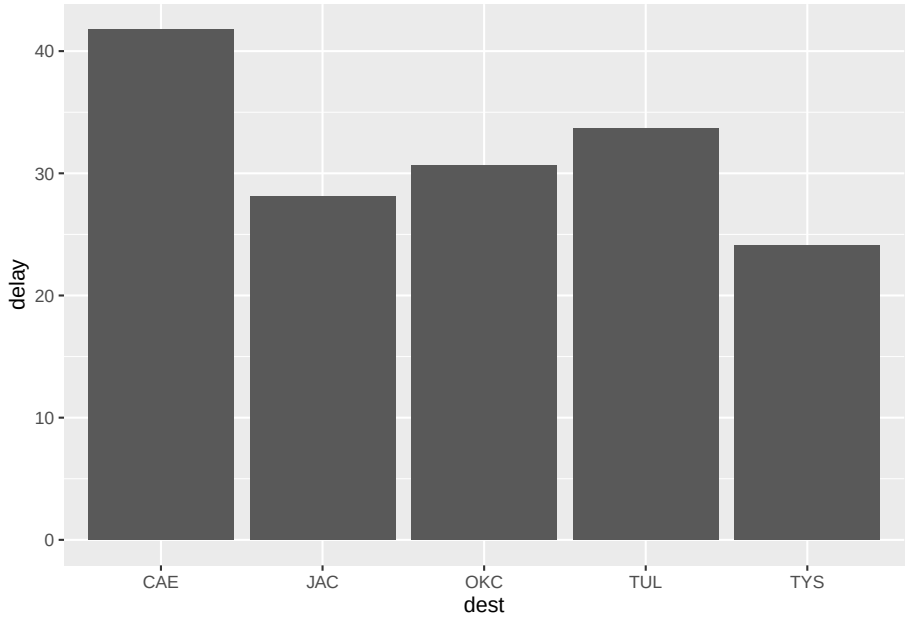

Perceba que as colunas estão organizadas em ordem alfabética. Para organizá-las em ordem decrescente da variável delay, podemos usar a função reorder:

```
top_5 %>%
  ggplot(aes(x = reorder(dest, -delay), y = delay)) +
  geom_col()
```

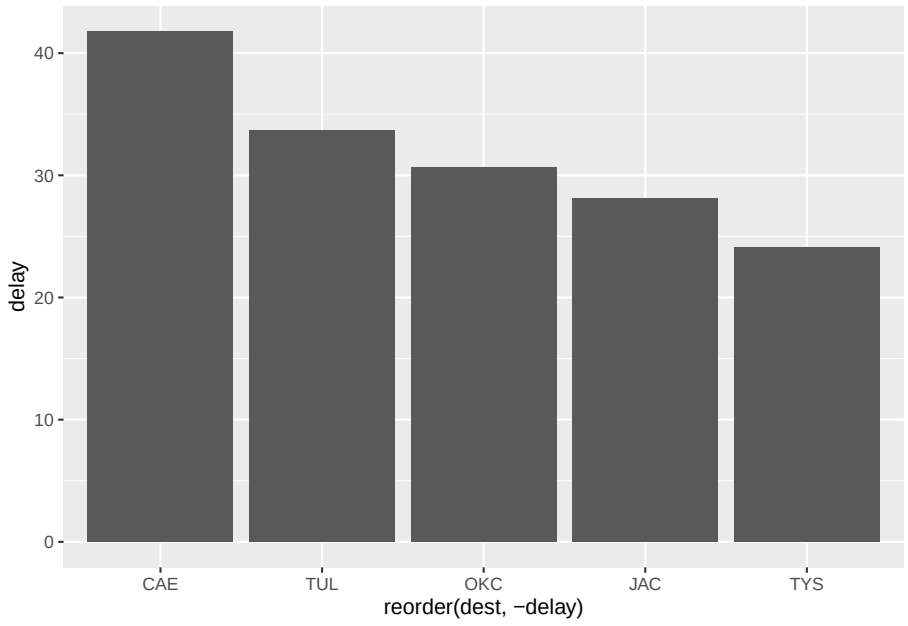

Podemos pintar todas as colunas da mesma cor:

```
top_5 %>%
  ggplot(aes(x = reorder(dest, -delay), y = delay)) +
  geom_col(fill = "lightblue")
```

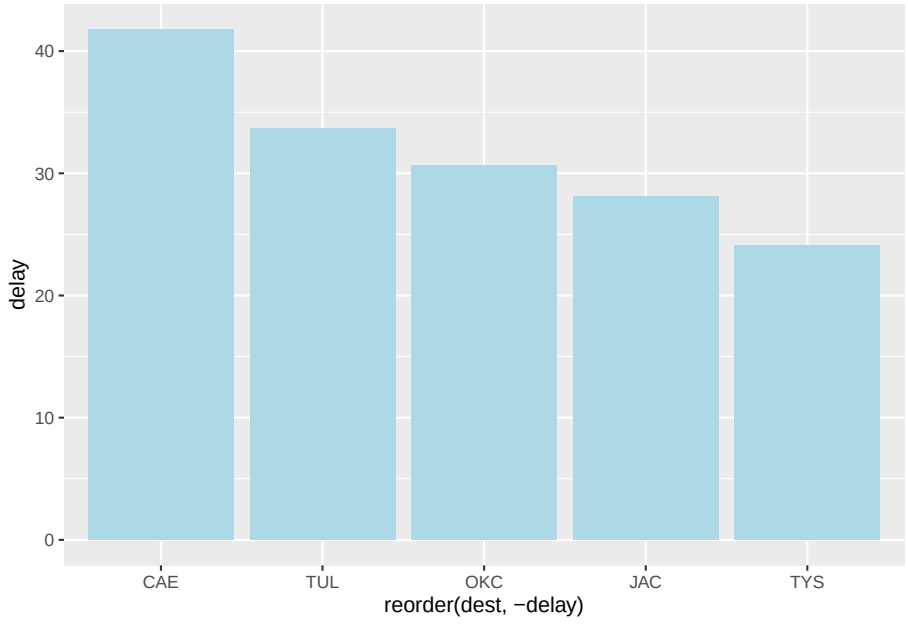

Vamos agora alterar os títulos e a aparência do gráfico:

```
top_5 %>%
  ggplot(aes(x = reorder(dest, -delay), y = delay)) +
  geom_col(fill = "lightblue") +
  labs(title = "Destinos com maior atraso médio (top 5)",
       y = "Atraso (em minutos)",
       x = "") +
  theme_minimal()
```

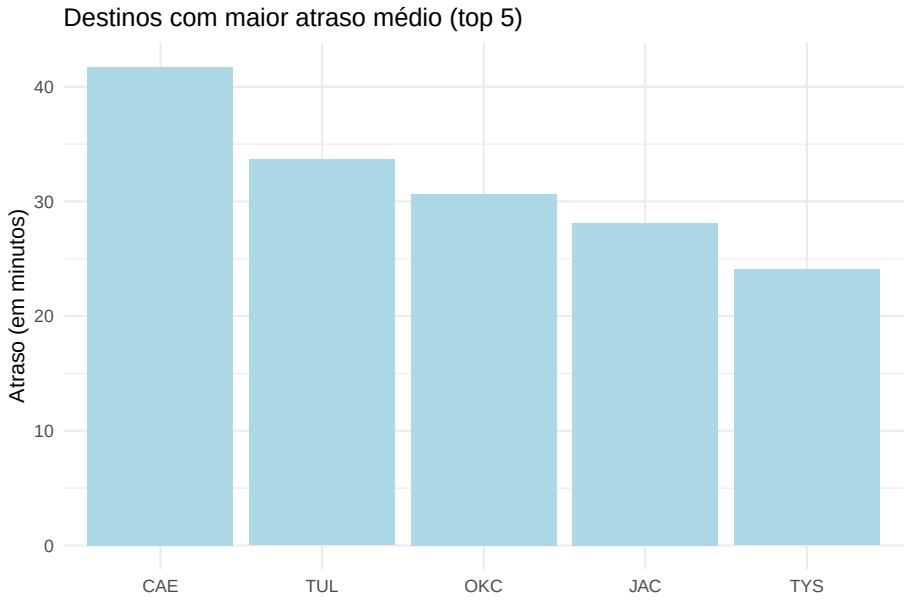

Veja mais detalhes em:

- https://ggplot2-book.org/
- https://www.r-graph-gallery.com/index.html
- https://www.data-to-viz.com/
- https://rstudio.com/wp-content/uploads/2015/03/ggplot2-cheatsheet.pdf

References

- Cotton, R. (2013). Learning R: a step-by-step function guide to data analysis. " O'Reilly Media, Inc.".
- Wickham, H., Çetinkaya-Rundel, M., & Grolemund, G. (2023). R for Data Science. " O'Reilly Media, Inc.".